

Classificazione delle Regioni Europee per Livello di Sviluppo

Analisi di classificazione sui dati Eurostat NUTS-2 (2021)

Martina Speciale

2026-09-06

1 Introduzione

La politica di coesione dell'UE classifica le regioni NUTS-2 in tre categorie — *meno sviluppate*, *in transizione* e *più sviluppate* — in base al PIL pro capite (PPS) rispetto alla media UE, e assegna i fondi strutturali di conseguenza.

Obiettivo.

- **Predire** la categoria di sviluppo con indicatori diversi dal livello di PIL pro capite.
- **Confrontare** KNN, LDA e QDA sullo stesso training/test split.
- **Valutare** la capacità predittiva su regioni non usate nella stima.

Fonte. Dati **Eurostat**, anno 2021, livello NUTS-2, accessibili via API. L'anno 2021 è usato perché, tra gli anni controllati, è il più recente con tutti gli indicatori disponibili nello stesso momento.

Dataset di partenza:

- **tgs00006:** PIL pro capite PPS rispetto alla media UE; serve solo a definire la classe.
- **tgs00010:** tasso di disoccupazione.
- **tgs00109:** quota di popolazione adulta con istruzione terziaria.
- **tgs00042:** spesa in R&S in percentuale del PIL.
- **tgs00039:** occupazione nei settori high-tech, in percentuale degli occupati.
- **isoc_r_broad_h:** famiglie con accesso a banda larga.

Struttura dei dati:

- **Dataset raw:** ogni indicatore nasce come tabella Eurostat separata, filtrata su anno 2021 e regioni NUTS-2.
- **Unione:** le tabelle vengono unite con `inner_join` usando `geo`, il codice della regione.
- **Risposta da predire:** dal PIL pro capite PPS (`gdp_pps_pct`) si crea `dev_class`: sotto 75% = meno sviluppata, tra 75% e 100% = transizione, sopra 100% = più sviluppata.
- **Dataset finale:** una riga per regione, con `geo`, `country`, `region`, `dev_class` e i cinque predittori. Dopo aver creato la classe, il PIL viene escluso dai dati usati dai modelli.
- **Anni più recenti:** 2022, 2023, 2024 e 2025 non danno lo stesso dataset completo, perché manca almeno uno degli indicatori selezionati.

Il codice R completo è allegato come file separato (`R/01_load_data.R` – `R/04_evaluation.R`).

2 I Dati

Table 1: Predittori utilizzati (anno 2021, NUTS-2). Il PIL pro capite PPS definisce la classe e non è usato come predittore.

Variabile	Unità	Descrizione
unemp_rate	% forza lavoro	Tasso di disoccupazione
educ_tertiary	% pop. 25-64	Istruzione terziaria
rnd_gdp_pct	% PIL	Spesa R&S
hitech_emp_pct	% occupati	Occupazione high-tech
broadband_pct	% famiglie	Accesso banda larga

Il dataset comprende:

- **155 regioni NUTS-2** di 23 paesi UE.
- **Classi:** 52 meno sviluppate, 50 in transizione, 53 più sviluppate.
- **Partizione:** 75% training (116) / 25% test (39). Nel codice il seed è fissato a 2026 per rendere riproducibile la divisione.

Table 2: Mediane dei predittori per categoria di sviluppo (dataset completo). La tabella confronta i valori centrali delle tre classi, senza assumere che ogni variabile separi bene tutte le categorie.

Variabile	Meno sv.	Transiz.	Più sv.
Disoccupazione (%)	9.1	8.3	5.9
Educ. terziaria (%)	23.4	36.1	43.3
R&S (% PIL)	0.7	1.2	1.7
High-tech (% occupati)	3.0	3.7	5.3
Banda larga (%)	93.4	93.3	95.4

Lettura delle mediane:

- **Istruzione, R&S e high-tech:** valori centrali più alti nelle regioni più sviluppate.
- **Banda larga:** differenze contenute, perché l'accesso è già alto in quasi tutte le regioni.
- **Disoccupazione:** più bassa nelle regioni più sviluppate, ma la transizione resta vicina alla classe meno sviluppata.




Figure 1: Distribuzione dei predittori per categoria di sviluppo (training set). Il grafico confronta la distribuzione dei cinque predittori nelle tre classi: si vedono differenze nei valori mediani, ma anche sovrapposizione tra categorie.

Lettura del grafico. Istruzione terziaria, R&S e banda larga tendono a crescere nelle classi più sviluppate, mentre la disoccupazione tende a essere più bassa. I box però si sovrappongono in tutte le variabili: nessun predittore, da solo, separa perfettamente le tre classi.




Figure 2: Disoccupazione vs istruzione terziaria per categoria. La separazione tra classi è parziale: le regioni meno sviluppate tendono verso disoccupazione più alta e istruzione più bassa, ma c'è sovrapposizione.

Lettura del grafico. Le regioni meno sviluppate si concentrano su bassa istruzione e disoccupazione più alta; le più sviluppate hanno profilo opposto. La classe di transizione resta nella zona centrale e si sovrappone alle altre.

3 Metodi e Selezione del Modello

Vengono applicati tre classificatori:

- **KNN:** metodo non parametrico, basato sulle regioni più vicine.
- **LDA:** frontiere lineari e matrice di covarianza comune.
- **QDA:** frontiere quadratiche e covarianza stimata per classe.

Prima della classificazione:

- **Standardizzazione:** tutti i predittori sono portati a z-score.
- **Scelta di KNN:** si provano i valori $K = 1, \dots, 25$.
- **CV:** convalida incrociata a 10 fold sul solo training set; i 10 fold sono i gruppi della CV, mentre K è il numero di vicini del KNN.
- **Test set:** usato solo alla fine, dopo aver scelto K e stimato i modelli, per misurare la previsione su dati non usati nelle decisioni precedenti.




Figure 3: Errore CV a 10 fold per KNN al variare del numero di vicini. La curva non è monotona: oscilla tra i diversi valori di K; il valore scelto è indicato dalla linea rossa.

Lettura del grafico. La linea mostra l'errore medio di validazione per ciascun numero di vicini. $K=6$ è scelto perché ha l'errore medio più basso, anche se i valori vicini non seguono un andamento perfettamente regolare.

4 Risultati

Table 3: Confronto dei classificatori sul test set (39 regioni).
Metriche macro-mediate tra le tre classi.

Modello	Accuratezza	Sensitività (macro)	Specificità (macro)
KNN	0.641	0.636	0.814
LDA	0.692	0.689	0.847
QDA	0.769	0.766	0.880

Le metriche utilizzate sono:

- **Accuratezza:** quota totale di regioni classificate correttamente.
- **Sensitività (macro):** per ogni classe misura quante regioni vere di quella classe sono riconosciute; poi fa la media tra le tre classi.
- **Specificità (macro):** per ogni classe misura quante regioni non appartenenti a quella classe sono escluse correttamente; poi fa la media tra le tre classi.

Dal confronto emerge che:

- **Miglior modello:** QDA, con accuratezza **76.9%** sul test set (30 regioni corrette su 39).
- **Confronto base:** scegliere sempre la classe più frequente del test avrebbe accuratezza circa **41%**, quindi QDA migliora nettamente rispetto a una regola banale.

- **QDA:** usa frontiere quadratiche, quindi riesce a catturare una separazione meno lineare tra le classi.
- **LDA:** resta competitivo, ma la frontiera lineare perde alcuni casi della classe di transizione.
- **KNN:** più debole in 5 dimensioni con soli 116 casi di training.
- **Interpretazione:** le classi sono separabili, ma non in modo perfettamente lineare nello spazio degli indicatori strutturali.




Figure 4: Matrici di confusione sul test set per KNN, LDA e QDA. Ogni pannello confronta classe reale e classe predetta; i valori sulla diagonale sono le classificazioni corrette.

Lettura del grafico. La diagonale indica le classificazioni corrette. QDA ha la diagonale più piena, soprattutto sulle classi estreme; gli errori si concentrano ancora sulla transizione, che è la categoria più ambigua.




Figure 5: Spazio discriminante LDA (training set). LD1 separa le regioni meno sviluppate da quelle più sviluppate; LD2 differenzia la classe di transizione.

Lettura del grafico. Nel piano LDA le regioni meno sviluppate e più sviluppate occupano zone abbastanza distinte; le regioni in transizione stanno più al centro. Questo aiuta a capire perché un modello più flessibile come QDA può migliorare il risultato finale.

5 Conclusioni

In sintesi:

- **Risultato principale:** QDA raggiunge un'accuratezza dell'**76.9%** (30/39) usando indicatori diversi dal PIL pro capite.
- **Lettura dell'accuratezza:** il valore è buono rispetto al baseline (41%), ma va interpretato come risultato esplorativo perché il test set contiene solo 39 regioni.
- **Classe critica:** la categoria *transizione* è la più difficile, perché condivide caratteristiche con entrambe le classi adiacenti.
- **Implicazione:** il modello può essere letto come indicazione esplorativa della convergenza reale tra regioni.
- **Limiti:** il campione è contenuto (155 regioni), esclude aree con dati mancanti e fotografa un solo anno, il 2021.